



Engenharia de Controle e Automação

Controle Preditivo



**Prof. Dr.
Paulo J. D. O. Evald**



Prof. Dr.
Paulo J. D. O. Evald



Centro de Engenharias
Sala 211



paulo.evald@ufpel.edu.br

“ Objetivos da aula:

- Controle Preditivo
 - Introdução;
 - Modelo de espaço de estados aumentado.



Controle Preditivo

O objetivo geral do projeto de controle preditivo por modelo é calcular uma trajetória de uma variável manipulada u para otimizar o comportamento futuro da saída da planta y ;

A otimização é realizada dentro de uma janela de tempo limitada, fornecendo informações da planta no início da janela de tempo;

Há 3 fatores fundamentais nesse processo:

- Um modelo verossímil;

- Acesso às medidas no instante de tempo atual;

- O controlador preditivo.

Controle Preditivo

Termos básicos do Controle Preditivo:

Janela de horizonte móvel: é dependente do tempo, inicia em um tempo arbitrário t_i e vai até $t_i + T_p$, sendo T_p o comprimento constante da janela;

Horizonte de predição: indica até onde deseja-se predizer, cujo valor é T_p ;

Receding Horizon Control: embora a trajetória ótima do sinal de controle futuro seja completamente descrita dentro da janela do horizonte móvel, a entrada de controle real para a planta utiliza apenas a primeira amostra do sinal de controle, desprezando as demais;

Função de custo (J): a ação de controle ótima é encontrada minimizando esta função de custo dentro da janela de otimização.

Controle Preditivo

Modelos de resposta ao impulso finito (FIR): usado na formulação de *Dynamic Matrix Control* (DMC) e *Quadratic DMC*

Fornece uma descrição transparente do atraso de tempo do processo, tempo de resposta e ganho;

Frequentemente, utiliza modelos de alta ordem (30 a 60 coeficientes da resposta ao impulso);

Limitado a plantas estáveis;

Modelo de resposta ao degrau: utilizado no *Generalized Predictive Control* (GPC);

Aplicável em plantas estáveis e instáveis;

Geralmente, não apresenta alto desempenho em sistemas multivariáveis.

Controle Preditivo

Modelo em espaço de estados: as informações atuais necessárias para prever o futuro são representadas pela variável de estado no momento atual;

Para uma planta SISO (*Single Input Single Output*),

$$\begin{aligned}x_m(k+1) &= A_m x_m(k) + B_m u(k), \\ y(k) &= C_m x_m(k),\end{aligned}$$

Obs.: A forma original no espaço de estados é $y(k) = C_m x_m(k) + D_m u(k)$. Porém, como o *receding horizon control* usa uma informação atual da planta para predição do sistema e da ação de controle, assume-se implicitamente que a entrada $u(k)$ não pode afetar a saída $y(k)$ ao mesmo tempo em que é medida. Assim, $D = 0$ no modelo da planta.

Controle Preditivo

Aplicando $-x_m(k)$ em ambos lados do modelo, obtém-se

$$x_m(k+1) - x_m(k) = A_m(x_m(k) - x_m(k-1)) + B_m(u(k) - u(k-1))$$

Logo,

$$\Delta x_m(k+1) = x_m(k+1) - x_m(k)$$

que pode ser escrita de forma equivalente como

$$\Delta x_m(k) = x_m(k) - x_m(k-1)$$

Controle Preditivo

A equação da diferença da ação de controle é

$$\Delta u(k) = u(k) - u(k - 1)$$

Portanto, a representação no espaço de estados por equação de diferenças é

$$\Delta x_m(k + 1) = A_m \Delta x_m(k) + B_m \Delta u(k)$$

Entrada da
planta



Controle Preditivo

O novo vetor de variável de estado é

$$x(k) = [\Delta x_m(k)^T \ y(k)]^T$$

Ainda,

$$y(k+1) - y(k) = C_m(x_m(k+1) - x_m(k))$$

$$= C_m \underline{\Delta x_m(k+1)}$$



$$= C_m A_m \Delta x_m(k) + C_m B_m \Delta u(k)$$

$$\Delta x_m(k+1) = A_m \Delta x_m(k) + B_m \Delta u(k)$$

Controle Preditivo

Assim, o modelo aumentado usado no controle preditivo é

$$\overbrace{\begin{bmatrix} \Delta x_m(k+1) \\ y(k+1) \end{bmatrix}}^{x(k+1)} = \overbrace{\begin{bmatrix} A_m & o_m^T \\ C_m A_m & 1 \end{bmatrix}}^A \overbrace{\begin{bmatrix} \Delta x_m(k) \\ y(k) \end{bmatrix}}^{x(k)} + \overbrace{\begin{bmatrix} B_m \\ C_m B_m \end{bmatrix}}^B \Delta u(k)$$

$$y(k) = \overbrace{\begin{bmatrix} o_m & 1 \end{bmatrix}}^C \begin{bmatrix} \Delta x_m(k) \\ y(k) \end{bmatrix}$$

onde $o_m = \overbrace{[0 \ 0 \ \dots \ 0]}^{n_1}$, sendo n_1 a dimensão do vetor de variáveis de estado da planta, ou seja, antes de aumentar o modelo.

Controle Preditivo

Exemplo: Determine o modelo aumentado do sistema representado por

$$A_m = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}; B_m = \begin{bmatrix} 0.5 \\ 1 \end{bmatrix}; C_m = [1 \ 0] .$$

Solução: Note que $n_1 = 2$ e portanto $o_m = [0 \ 0]$. Logo, o modelo aumentado é

$$A = \begin{bmatrix} A_m & o_m^T \\ C_m A_m & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad B = \begin{bmatrix} B_m \\ C_m B_m \end{bmatrix} = \begin{bmatrix} 0.5 \\ 1 \\ 0.5 \end{bmatrix} \quad C = [o_m \ 1] = [0 \ 0 \ 1]$$

Como pode ser notado há 3 integradores no modelo aumentado, onde 2 são da própria planta e 1 é adicionado pela transformação.

Controle Preditivo

Prática: Implemente um script para obter o modelo aumentado discreto a partir das matrizes que representam o seguinte sistema no espaço de estados em tempo contínuo:

$$\begin{aligned}\dot{x}_m(t) &= \begin{bmatrix} 0 & 1 & 0 \\ 3 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} x_m(t) + \begin{bmatrix} 1 \\ 1 \\ 3 \end{bmatrix} u(t) \\ y(t) &= \begin{bmatrix} 0 & 1 & 0 \end{bmatrix} x_m(t).\end{aligned}$$

Discretize com $T_s = 1$.

Controle Preditivo

$A_c = \begin{bmatrix} 0 & 1 & 0; & 3 & 0 & 1; & 0 & 1 & 0 \end{bmatrix};$

$B_c = \begin{bmatrix} 1; & 1; & 3 \end{bmatrix};$

$C_c = \begin{bmatrix} 0 & 1 & 0 \end{bmatrix};$

$D_c = \text{zeros}(1, 1);$

$T_s = 1;$

$[A_d, B_d, C_d, D_d] = \text{c2dm}(A_c, B_c, C_c, D_c, T_s);$

$[m_1, n_1] = \text{size}(C_d);$

$[n_1, n_{in}] = \text{size}(B_d);$

$A_e = \text{eye}(n_1+m_1, n_1+m_1);$

$A_e(1:n_1, 1:n_1) = A_d;$

$A_e(n_1+1:n_1+m_1, 1:n_1) = C_d * A_d;$

$B_e = \text{zeros}(n_1+m_1, n_{in});$

$B_e(1:n_1, :) = B_d;$

$B_e(n_1+1:n_1+m_1, :) = C_d * B_d;$

$C_e = \text{zeros}(m_1, n_1+m_1);$

$C_e(:, n_1+1:n_1+m_1) = \text{eye}(m_1, m_1);$

Controle Preditivo

O próximo passo no projeto de um sistema de controle preditivo é calcular a predição da saída da planta com o sinal de controle futuro como as variáveis ajustáveis. Essa previsão é descrita em uma janela de otimização;

Assumindo que no instante de amostragem k_i , o vetor de variável de estado $x(k_i)$ está disponível para medição, então o estado $x(k_i)$ fornece a informação atual da planta. Logo, a trajetória de controle futuro é denotada por

$$\Delta u(k_i), \Delta u(k_i + 1), \dots, \Delta u(k_i + N_c - 1)$$

onde N_c é chamado de horizonte de controle, escolhido para ser menor que (ou igual a) o horizonte de previsão N_p .

Controle Preditivo

Com a informação atual $x(k_i)$, as variáveis de estado futuras são previstas para N_p amostras (horizonte de previsão);

Obs.: a janela de otimização também tem comprimento N_p .

As variáveis de estado futuras são denotadas como

$$x(k_i + 1 \mid k_i), x(k_i + 2 \mid k_i), \dots, x(k_i + m \mid k_i), \dots, x(k_i + N_p \mid k_i)$$

Controle Preditivo

As variáveis de estado futuras são calculadas sequencialmente usando o conjunto de parâmetros de controle futuros:

$$x(k_i + 1 | k_i) = Ax(k_i) + B\Delta u(k_i)$$

$$x(k_i + 2 | k_i) = Ax(k_i + 1 | k_i) + B\Delta u(k_i + 1)$$

·
·
·

Controle Preditivo

As variáveis de estado futuras são calculadas sequencialmente usando o conjunto de parâmetros de controle futuros:

$$x(k_i + 1 | k_i) = Ax(k_i) + B\Delta u(k_i)$$

$$\begin{aligned} x(k_i + 2 | k_i) &= Ax(k_i + 1 | k_i) + B\Delta u(k_i + 1) \\ &= A^2x(k_i) + AB\Delta u(k_i) + B\Delta u(k_i + 1) \end{aligned}$$

·
·
·

Controle Preditivo

As variáveis de estado futuras são calculadas sequencialmente usando o conjunto de parâmetros de controle futuros:

$$x(k_i + 1 | k_i) = Ax(k_i) + B\Delta u(k_i)$$

$$\begin{aligned}x(k_i + 2 | k_i) &= Ax(k_i + 1 | k_i) + B\Delta u(k_i + 1) \\ &= A^2x(k_i) + AB\Delta u(k_i) + B\Delta u(k_i + 1)\end{aligned}$$

$$\vdots$$

$$\begin{aligned}x(k_i + N_p | k_i) &= A^{N_p}x(k_i) + A^{N_p-1}B\Delta u(k_i) + A^{N_p-2}B\Delta u(k_i + 1) \\ &\quad + \dots + A^{N_p-N_c}B\Delta u(k_i + N_c - 1).\end{aligned}$$

Controle Preditivo

Das variáveis de estado previstas, as variáveis de saída futuras são obtidas por substituição,

$$y(k_i + 1 | k_i) = CAx(k_i) + CB\Delta u(k_i)$$

$$y(k_i + 2 | k_i) = CA^2x(k_i) + CAB\Delta u(k_i) + CB\Delta u(k_i + 1)$$

$$y(k_i + 3 | k_i) = CA^3x(k_i) + CA^2B\Delta u(k_i) + CAB\Delta u(k_i + 1) + CB\Delta u(k_i + 2) + CB\Delta u(k_i + 2)$$

$$\vdots$$

$$y(k_i + N_p | k_i) = CA^{N_p}x(k_i) + CA^{N_p-1}B\Delta u(k_i) + CA^{N_p-2}B\Delta u(k_i + 1) + \dots + CA^{N_p-N_c}B\Delta u(k_i + N_c - 1).$$

Controle Preditivo

Definindo os vetores de predição da resposta do sistema Y e ação de controle futuras ΔU ,

$$Y = [y(k_i + 1 | k_i) \ y(k_i + 2 | k_i) \ y(k_i + 3 | k_i) \ \dots \ y(k_i + N_p | k_i)]^T$$

$$\Delta U = [\Delta u(k_i) \ \Delta u(k_i + 1) \ \Delta u(k_i + 2) \ \dots \ \Delta u(k_i + N_c - 1)]^T$$

cujas dimensões de Y e ΔU são N_p e N_c , respectivamente. Em uma forma compacta,

$$Y = Fx(k_i) + \Phi \Delta U$$

onde

$$F = \begin{bmatrix} CA \\ CA^2 \\ CA^3 \\ \vdots \\ CA^{N_p} \end{bmatrix}; \Phi = \begin{bmatrix} CB & 0 & 0 & \dots & 0 \\ CAB & CB & 0 & \dots & 0 \\ CA^2B & CAB & CB & \dots & 0 \\ \vdots & & & & \\ CA^{N_p-1}B & CA^{N_p-2}B & CA^{N_p-3}B & \dots & CA^{N_p-N_c}B \end{bmatrix}$$

Controle Preditivo

Otimização

Para uma dada referência $r(k_i)$ no tempo de amostragem k_i , dentro de um horizonte de predição, o objetivo do controlador preditivo é minimizar o erro entre a saída prevista e a referência;

Assume-se que o sinal de referência permanece constante na janela de otimização;

O objetivo é alcançado ao encontrar o vetor de parâmetro de controle ΔU que minimiza a função de erro.

Controle Preditivo

Definindo a informação da referência da seguinte forma

$$R_s^T = \overbrace{[1 \ 1 \ \dots \ 1]}^{N_p} r(k_i)$$

A função-custo J que reflete o objetivo de controle é

$$J = (R_s - Y)^T (R_s - Y) + \Delta U^T \bar{R} \Delta U$$

sendo a matriz diagonal dada por

$$\bar{R} = r_w I_{N_c \times N_c} \quad (r_w \geq 0)$$

e r_w é um parâmetro de ajuste para o desempenho do sistema em malha fechada.

Controle Preditivo

$$\bar{R} = r_w I_{N_c \times N_c} \quad (r_w \geq 0)$$

Se r_w for nulo, a função-custo é interpretada como a situação em que não há restrições quanto ao tamanho de ΔU , pois o objetivo é apenas tornar o erro o tão pequeno quanto possível;

Se r_w for grande, a função-custo é interpretada como a situação em que o tamanho de ΔU é relevante e o erro é reduzido cautelosamente.

Controle Preditivo

Para encontrar o ΔU ótimo que minimizará J , calcula-se

$$J = (R_s - Fx(k_i))^T (R_s - Fx(k_i)) - 2\Delta U^T \Phi^T (R_s - Fx(k_i)) + \Delta U^T (\Phi^T \Phi + \bar{R}) \Delta U$$

Da primeira derivada da função-custo J , obtém-se

$$\frac{\partial J}{\partial \Delta U} = -2\Phi^T (R_s - Fx(k_i)) + 2(\Phi^T \Phi + \bar{R}) \Delta U$$

Sendo a condição necessária para minimizar J é

$$\frac{\partial J}{\partial \Delta U} = 0$$

Controle Preditivo

Portanto, assumindo que a matriz Hessiana $(\Phi^T \Phi + \bar{R})^{-1}$ existe, então a solução ótima para o sinal de controle é

$$\Delta U = (\Phi^T \Phi + \bar{R})^{-1} \Phi^T (R_s - Fx(k_i))$$

onde

$$R_s = \overbrace{[1 \ 1 \ 1 \ \dots \ 1]^T}^{N_p} r(k_i) = \bar{R}_s r(k_i)$$

e

$$\bar{R}_s = \overbrace{[1 \ 1 \ 1 \ \dots \ 1]^T}^{N_p}$$

Controle Preditivo

Exemplo: Considere o sistema SISO

$$\begin{aligned}x_m(k+1) &= ax_m(k) + bu(k) \\ y(k) &= x_m(k),\end{aligned}$$

onde $a = 0,8$ and $b = 0,1$.

- 1) Encontre o modelo de espaço de estados aumentado.
- 2) Assumindo um horizonte de previsão $N_p = 10$ e horizonte de controle $N_c = 4$, calcule os componentes que formam a previsão de Y , e as quantidades $\Phi^T \Phi$, $\Phi^T F$ e $\Phi^T \bar{R}_s$.
- 3) Supondo que em um instante k ($k = 10$ para este exemplo), $r(k) = 1$ e o vetor de estado $x(k) = [0.1 \ 0.2]^T$, encontre a solução ótima ΔU em relação aos casos em que

$r_w = 0$ e $r_w = 10$.

Controle Preditivo

1) Modelo de espaço de estados aumentado

$$A = \begin{bmatrix} A_m & o_m^T \\ C_m A_m & 1 \end{bmatrix} \quad B = \begin{bmatrix} B_m \\ C_m B_m \end{bmatrix} \quad C = [o_m \ 1]$$

Solução: $A_m = a$, $B_m = b$, $C_m = 1$ e $o_m = [0]$. Portanto,

$$\begin{bmatrix} \Delta x_m(k+1) \\ y(k+1) \end{bmatrix} = \begin{bmatrix} a & 0 \\ a & 1 \end{bmatrix} \begin{bmatrix} \Delta x_m(k) \\ y(k) \end{bmatrix} + \begin{bmatrix} b \\ b \end{bmatrix} \Delta u(k)$$
$$y(k) = [0 \ 1] \begin{bmatrix} \Delta x_m(k) \\ y(k) \end{bmatrix}.$$

Controle Preditivo

2) Para um horizonte de predição $N_p = 10$ e um horizonte de controle $N_c = 4$, têm-se

$$F = \begin{bmatrix} CA \\ CA^2 \\ CA^3 \\ CA^4 \\ CA^5 \\ CA^6 \\ CA^7 \\ CA^8 \\ CA^9 \\ CA^{10} \end{bmatrix}; \Phi = \begin{bmatrix} CB & 0 & 0 & 0 \\ CAB & CB & 0 & 0 \\ CA^2B & CAB & CB & 0 \\ CA^3B & CA^2B & CAB & CB \\ CA^4B & CA^3B & CA^2B & CAB \\ CA^5B & CA^4B & CA^3B & CA^2B \\ CA^6B & CA^5B & CA^4B & CA^3B \\ CA^7B & CA^6B & CA^5B & CA^4B \\ CA^8B & CA^7B & CA^6B & CA^5B \\ CA^9B & CA^8B & CA^7B & CA^6B \end{bmatrix}$$

Solução:

$$\Phi^T \Phi = \begin{bmatrix} 1.1541 & 1.0407 & 0.9116 & 0.7726 \\ 1.0407 & 0.9549 & 0.8475 & 0.7259 \\ 0.9116 & 0.8475 & 0.7675 & 0.6674 \\ 0.7726 & 0.7259 & 0.6674 & 0.5943 \end{bmatrix}$$

$$\Phi^T F = \begin{bmatrix} 9.2325 & 3.2147 \\ 8.3259 & 2.7684 \\ 7.2927 & 2.3355 \\ 6.1811 & 1.9194 \end{bmatrix}; \Phi^T \bar{R}_s = \begin{bmatrix} 3.2147 \\ 2.7684 \\ 2.3355 \\ 1.9194 \end{bmatrix}$$

Controle Preditivo

3) No instante $k = 10$, o vetor de estado $x(k) = [0,1 \ 0,2]^T$.

Solução:

Quando $r_w = 0$, o ΔU ótimo é

$$\Delta U = (\Phi^T \Phi)^{-1} (\Phi^T R_s - \Phi^T F x(k_i)) = [7.2 \ -6.4 \ 0 \ 0]^T$$


Quando $r_w = 10$, o ΔU ótimo é

$$\begin{aligned} \Delta U &= (\Phi^T \Phi + 10 \times I)^{-1} (\Phi^T R_s - \Phi^T F x(k_i)) \\ &= [0.1269 \ 0.1034 \ 0.0829 \ 0.065]^T. \end{aligned}$$

Note que energia de controle é distribuída ao longo de um período mais longo de tempo futuro.

Controle Preditivo

Prática



Controle Preditivo

Implemente um algoritmo que calcule $\Phi^T \Phi$, $\Phi^T F$ e $\Phi^T \bar{R}_s$.

Verifique se o programa está correto inserindo o exemplo anterior $A_p = 0.8$, $B_p = 0.1$, $C_p = 1$, $N_c = 4$ and $N_p = 10$.

Dica: A matriz Φ é uma matriz Toeplitz, que é criada definindo sua primeira coluna, e a próxima coluna é obtida deslocando a coluna anterior.

Controle Preditivo

```
function [ Phi_Phi, Phi_F, Phi_R, A_e, B_e, C_e ] = mpcgain( Ap, Bp, Cp, Nc, Np);
```

% Crie o modelo aumentado para o projeto MPC.

```
[ m1, n1 ] = size( Cp );
```

```
(...)
```

```
[ n1, n_in ] = size( Bp );
```

```
B_e = zeros( n1+m1, n_in );
```

```
A_e = eye(n1+m1, n1+m1);
```

```
B_e( 1:n1, : ) = Bp;
```

```
A_e( 1:n1, 1:n1 ) = Ap;
```

```
B_e( n1+1:n1+m1, : ) = Cp*Bp;
```

```
A_e( n1+1:n1+m1, 1:n1 ) = Cp*Ap;
```

```
C_e = zeros( m1, n1+m1 );
```

```
(...)
```

```
C_e( :, n1+1:n1+m1 ) = eye( m1,m1 );
```

Controle Preditivo

% Crie F e Phi

n = n1 + m1;

h(1,:) = C_e;

F(1,:) = C_e*A_e;

for k=2:Np

h(k,:) = h(k-1,:)*A_e;

F(k,:) = F(k-1,:)*A_e;

end

v = h*B_e;

Phi = zeros(Np, Nc);

% Declara a dimensão de Phi

Phi(:, 1) = v;

% Primeira coluna de Phi

for i=2:Nc

Phi(:, i) = [zeros(i-1, 1); v(1:Np-i+1, 1)]; %Toeplitz
matrix

end

BarRs = ones(Np, 1);

Phi_Phi = Phi' * Phi;

Phi_F = Phi' * F;


Phi_R = Phi' * BarRs;

Controle Preditivo

Insira no workspace $A_p = 0.8$, $B_p = 0.1$, $C_p = 1$, $N_c = 4$ e $N_p = 10$;

Execute a função `mpcgain`;

Compare com os resultados obtidos manualmente. Se estiverem iguais, o programa está correto.



Próxima aula:

Receding Horizon Control (RHC)

Exercícios + Simulações
(aula no laboratório de informática)



Bibliografia Básica

NISE, N. S., **Engenharia de sistemas de controle**, 5ª Edição, LTC, 2009.


OGATA, K., **Engenharia de controle moderno**, 5ª Edição, Pearson, 2011.

DORF, R. C.; BISHOP, R. H., **Sistemas de controle modernos**, 11ª Edição, LTC, 2009.

SEBORG, D. E.; EDGAR, T. F.; MELLICHAMP, D. A.; DOYLE, F. J., **Process dynamics and control**, 3ª Edition, John Wiley & Sons, 2010.

BAZANELLA, A. S.; GOMES da SILVA Jr., J. M., **Sistemas de controle: princípios e métodos de projeto**, 1ª Edição, Editora UFRGS, 2005.

CHEN, C. T., **Linear system theory and design**, 3ª Edição, Oxford University Press, 1999.



Bibliografia Complementar

CAMACHO E. F. Camacho; BORDONS C. A. Bordons. **Model Predictive Control in the Process Industry**. Springer-Verlag, Berlin, Heidelberg. 1997.

BORRELLI, F., BEMPORAD, A., MORARI, M. **Predictive Control for Linear and Hybrid Systems**. Cambridge: Cambridge University Press. 2017.

